

UNIVERSIDAD COOPERATIVA DE COLOMBIA

FACULTAD DE INGENIERÍA

PROGRAMA DE INGENIERÍA DE SISTEMAS / SOFTWARE

ASIGNATURA: Inteligencia de Negocios y Minería de Datos

SEMESTRE: Séptimo Semestre

ACTIVIDAD: Laboratorio 1 - Modelado Predictivo con Regresión Lineal Múltiple bajo el Marco CRISP-DM

DATOS DE ENTREGA

Estudiante:	Jack Limas
Docente:	Docente de Inteligencia de Negocios y Minería de Datos
Fecha:	Octubre de 2026
Entorno de Ejecución:	Python 3.11, Scikit-Learn, Streamlit, Pandas
Repositorio / Despliegue:	Streamlit Community Cloud / GitHub

\newpage

TABLA DE CONTENIDO

1. [Introducción y Objetivos](#)
 2. [Marco Metodológico: Metodología CRISP-DM](#)
 3. [Desarrollo del Ejercicio 1: Predicción del Precio del Dólar](#)
 4. [Desarrollo del Ejercicio 2: Predicción de Niveles de Glucosa en Sangre](#)
 5. [Desarrollo del Ejercicio 3: Predicción de Consumo de Energía Eléctrica](#)
 6. [Resumen Comparativo de Métricas](#)
 7. [Arquitectura de Despliegue y Persistencia \(Streamlit & Joblib\)](#)
 8. [Galería de Evidencias Visuales y Gráficos](#)
 9. [Conclusiones](#)
 10. [Referencias y Recursos Técnicos](#)
-

1. Introducción y Objetivos

1.1 Introducción

La minería de datos y la inteligencia de negocios moderna exigen transformar datos crudos en conocimiento accionable y herramientas interactivas de toma de decisiones. En este laboratorio se abordan tres problemas reales de naturaleza cuantitativa:

1. **Mercado Cambiario:** Modelado econométrico del precio del dólar (COP) mediante variables macroeconómicas y factores temporales.


2. **Salud Preventiva y Medicina de Datos:** Estimación de niveles de glucosa basal a partir de indicadores biométricos y hábitos de vida.
3. **Optimización Energética:** Proyección del consumo eléctrico horario en función de la temperatura ambiente y ciclos de actividad semanal.

1.2 Objetivos

- **Objetivo General:** Desarrollar un sistema integral de minería de datos guiado por el estándar industrial CRISP-DM, que contemple desde la comprensión de datos hasta el despliegue de una plataforma web analítica reactiva.
- **Objetivos Específicos:**
 - Ajustar modelos matemáticos de Regresión Lineal Múltiple aplicando optimización por Mínimos Cuadrados Ordinarios (OLS).
 - Evaluar numéricamente la precisión y capacidad explicativa mediante R^2 , MSE y RMSE.
 - Ponderar el impacto relativo de las variables independientes para identificar factores críticos.
 - Implementar una interfaz gráfica moderna en **Streamlit** y serializar modelos con **Joblib**.
 - Documentar la estrategia de despliegue en la nube.

2. Marco Metodológico: Metodología CRISP-DM

El proyecto se estructuró rigurosamente en las seis fases de la metodología **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*):



1. **Comprensión del Negocio:** Formular los objetivos analíticos y definir las variables de respuesta continua (Y).
2. **Comprensión de los Datos:** Inspección de los datasets fuente (`dolar_data.csv`, `glucosa_data.csv`, `energia_data.csv`), analizando dimensionalidad, tipos de datos y estadísticas descriptivas.
3. **Preparación de los Datos:** Verificación de integridad, ausencia de registros nulos, y construcción de matrices de características $X \in \mathbb{R}^{n \times p}$ y vectores objetivo $Y \in \mathbb{R}^n$.
4. **Modelado:** Estimación paramétrica de vectores de pesos $\vec{\beta} = (X^T X)^{-1} X^T Y$ empleando `scikit-learn`.
5. **Evaluación:** Diagnóstico mediante bondad de ajuste (R^2), error cuadrático medio (MSE), desviación cuadrática media (RMSE) y coeficientes estandarizados.
6. **Despliegue:** Construcción de una aplicación web interactiva en tiempo real con **Streamlit**, empaquetamiento y preparación para despliegue en la nube pública.

3. Desarrollo del Ejercicio 1: Predicción del Precio del Dólar

3.1 Planteamiento y Datos

- **Dataset:** `data/dolar_data.csv` (500 registros, 4 atributos).
- **Variable Dependiente (Y):** `Precio_Dolar` (COP).
- **Variables Independientes (X):**
 - `Dia`: Día calendario del mes (1 a 31).
 - `Inflacion`: Tasa de inflación mensual registrada (fracción decimal).
 - `Tasa_interes`: Tasa de interés de referencia del banco central (%).

3.2 Ecuación Paramétrica del Modelo

$$\text{Precio_Dolar} = 3978.9846 + 4.9991 \cdot \text{Dia} - 338.0598 \cdot \text{Inflacion} - 2.5328 \cdot \text{Tasa_interes}$$

3.3 Interpretación de Coeficientes

- **Intercepto ($\beta_0 = 3978.9846$ COP):** Representa el valor base proyectado del dólar en el origen teórico del mes cuando la inflación y las tasas son nulas.
- $\beta_{\text{Dia}} = +4.9991$: Por cada día calendario adicional, el precio del dólar experimenta un incremento medio constante de **~5.00 COP**, reflejando la tendencia temporal alcista presente en el periodo.
- $\beta_{\text{Inflacion}} = -338.0598$: Un cambio de 1 unidad completa en la tasa generaría una variación de -338.06 COP; para una variación típica del 1% (0.01), el impacto marginal es de **-3.38 COP**.
- $\beta_{\text{Tasa_interes}} = -2.5328$: Por cada aumento de un punto porcentual (1.0%) en la tasa de interés, el precio de la divisa disminuye en **2.53 COP**, concordante con la teoría económica de apreciación cambiaria por atracción de capitales.

3.4 Métricas de Evaluación

Métrica	Valor Numérico	Interpretación Práctica
R^2 (Coeficiente de Determinación)	0.9952	El modelo explica el 99.52% de la varianza total del tipo de cambio.

Métrica	Valor Numérico	Interpretación Práctica
MSE (Error Cuadrático Medio)	2524.7152	Dispersión residual cuadrática.
RMSE (Error Cuadrático Raíz)	50.2465 COP	Error medio de pronóstico. Representa únicamente un 1.25% de error relativo frente al precio promedio (~\$4,000 COP).

3.5 Análisis de Peso e Impacto

- Coeficiente Estandarizado de **Dia**: **0.9978** (Variable de mayor impacto absoluto).
- Coeficiente Estandarizado de **Inflacion**: **-0.0023**.
- Coeficiente Estandarizado de **Tasa_interes**: **-0.0017**.

4. Desarrollo del Ejercicio 2: Predicción de Niveles de Glucosa en Sangre

4.1 Planteamiento y Datos

- **Dataset**: `data/glucosa_data.csv` (2,000 pacientes, 4 atributos).
- **Variable Dependiente (Y)**: **Nivel_Glucosa** (mg/dL en ayunas).
- **Variables Independientes (X)**:
 - **Edad**: Años cumplidos.
 - **IMC**: Índice de Masa Corporal (kg/m^2).
 - **Actividad_Fisica**: Horas semanales dedicadas a ejercicio físico moderado o vigoroso.

4.2 Ecuación Paramétrica del Modelo

$$\text{Nivel_Glucosa} = 66.3150 + 1.2337 \cdot \text{Edad} + 0.8832 \cdot \text{IMC} - 2.0104 \cdot \text{Actividad_Fisica}$$

4.3 Interpretación Clínica de Coeficientes

- **Intercepto ($\beta_0 = 66.3150 \text{ mg/dL}$)**: Concentración basal teórica de glucosa en condiciones basales mínimas.
- $\beta_{\text{Edad}} = +1.2337$: Cada año adicional de vida incrementa la glucosa en sangre en promedio **1.23 mg/dL**, asociado a la reducción progresiva de masa muscular y cambios en la sensibilidad pancreática.
- $\beta_{\text{IMC}} = +0.8832$: Por cada unidad de incremento en el IMC, la glucemia se eleva **0.88 mg/dL**, evidenciando la resistencia celular a la insulina producida por el tejido adiposo.
- $\beta_{\text{Actividad_Fisica}} = -2.0104$: Cada hora semanal de actividad física reduce la glucosa basal en **2.01 mg/dL**.

4.4 Métricas de Evaluación

Métrica	Valor Numérico	Interpretación Práctica
R^2	0.6855	Explica el 68.55% de la variabilidad biológica observada.
MSE	235.0377	Magnitud del error cuadrático residual.
RMSE	15.3309 mg/dL	Incertidumbre media de predicción para tamizaje médico preventivo.

4.5 Determinación de Factores Clave

- **Mayor Impacto Positivo (Factor de Riesgo Dominante):** **Edad** ($\beta = +1.2337$), seguida directamente por el **IMC**.
- **Mayor Impacto Negativo (Factor Protector Clave):** **Actividad_Fisica** ($\beta = -2.0104$), validando que el ejercicio regular es el hábito conductual más efectivo para la regulación metabólica.

5. Desarrollo del Ejercicio 3: Predicción de Consumo de Energía Eléctrica

5.1 Planteamiento y Datos

- **Dataset:** `data/energia_data.csv` (10,000 lecturas horarias, 4 atributos).
- **Variable Dependiente (Y):** **Consumo_Energia** (kWh).
- **Variables Independientes (X):**
 - **Temperatura:** Temperatura ambiental exterior en grados Celsius (°C).
 - **Hora:** Hora del día (0 a 23 hrs).
 - **Dia_Semana:** Día ordinal (1 = Lunes, ..., 7 = Domingo).

5.2 Ecuación Paramétrica del Modelo

$$\text{Consumo_Energia} = 101.3830 + 9.9660 \cdot \text{Temperatura} + 5.0118 \cdot \text{Hora} - 3.0892 \cdot \text{Dia_Semana}$$

5.3 Interpretación de Coeficientes y Dinámica Energética

- **Intercepto** ($\beta_0 = 101.3830 \text{ kWh}$): Consumo base mínimo de la red para mantener en funcionamiento servicios críticos permanentes.
- $\beta_{\text{Temperatura}} = +9.9660$: Por cada grado centígrado (°C) que aumenta la temperatura ambiental, la demanda eléctrica sube en **~9.97 kWh**, impulsada por sistemas de climatización (HVAC).
- $\beta_{\text{Hora}} = +5.0118$: Cada hora transcurrida a lo largo de la jornada eleva la demanda en **5.01 kWh** hasta las franjas horarias de máxima actividad laboral y doméstica.
- $\beta_{\text{Dia_Semana}} = -3.0892$: Conforme avanza la semana hacia el fin de semana, el consumo promedio diario decrece en **3.09 kWh**, por el cierre de industrias e instituciones.

5.4 Métricas de Evaluación

Métrica	Valor Numérico	Interpretación Práctica
R^2	0.9005	El 90.05% de las variaciones energéticas son capturadas por el modelo lineal.
MSE	405.2295	Error cuadrático en la estimación de potencia.
RMSE	20.1303 kWh	Desviación estándar de los residuales (~5.7% de error relativo frente a la media).

5.5 Variable de Mayor Impacto Global

- Coeficiente Estandarizado de **Temperatura**: **0.7814** (Impacto dominante).
- Coeficiente Estandarizado de **Hora**: **0.5435**.

- Coeficiente Estandarizado de `Dia_Semana`: **-0.0968**.

6. Resumen Comparativo de Métricas

A continuación se presenta la matriz consolidadora de rendimiento de los tres modelos implementados:

Proyecto	Variable Objetivo (Y)	Variables Predictoras (X)	R^2	RMSE	MSE	Factor Crítico
1. Precio del Dólar	<code>Precio_Dolar</code>	<code>Dia</code> , <code>Inflacion</code> , <code>Tasa_interes</code>	0.9952	50.25 COP	2,524.72	<code>Dia</code> (Tendencia temporal)
2. Niveles de Glucosa	<code>Nivel_Glucosa</code>	<code>Edad</code> , <code>IMC</code> , <code>Actividad_Fisica</code>	0.6855	15.33 mg/dL	235.04	<code>Actividad_Fisica</code> (Protector)
3. Consumo de Energía	<code>Consumo_Energia</code>	<code>Temperatura</code> , <code>Hora</code> , <code>Dia_Semana</code>	0.9005	20.13 kWh	405.23	<code>Temperatura</code> (Climatización)

7. Arquitectura de Despliegue y Persistencia (Streamlit & Joblib)

7.1 Persistencia de Modelos con Joblib

El entrenamiento de modelos estadísticos no debe ejecutarse en cada petición del usuario. Por ello, se implementó el almacenamiento binario en disco (`models/`):

- `modelo_dolar.joblib`
- `modelo_glucosa.joblib`
- `modelo_energia.joblib`

Cada archivo `.joblib` empaqueta una estructura serializada con:

1. Objeto del modelo optimizado (`scikit-learn LinearRegression`).
2. Listado de covariables y coeficientes matemáticos.
3. Métricas de evaluación calculadas (R^2 , MSE, RMSE).
4. Estadísticas descriptivas de los datos originales (mínimo, máximo, promedio) para restringir y preconfigurar los controles de la interfaz de usuario.

7.2 Interfaz Web Reactiva en Streamlit (`app.py`)

La aplicación integra:

- Menú de navegación lateral intuitivo con iconos temáticos.
- Formulario dinámico con campos numéricos y selectores sincronizados con los rangos reales de los datos.
- Motor de inferencia en tiempo real que aplica `joblib.load()` y realiza predicciones instantáneas.

- Despliegue de tarjetas de métricas tipo KPI, ecuaciones matemáticas en KaTeX y visualización de gráficos de dispersión.

8. Galería de Evidencias Visuales y Gráficos


A continuación se presentan los espacios formalmente definidos para adjuntar las gráficas generadas y capturas de pantalla de la aplicación:

8.1 Evidencia 1: Regresión Lineal del Precio del Dólar

Archivo generado: `static/plots/dolar_plots.png`
Descripción: Gráficos de dispersión y líneas de ajuste que muestran la relación bivariada de `Dia`, `Inflacion` y `Tasa_interes` frente a `Precio_Dolar`.

[PEGAR AQUÍ IMAGEN: dolar_plots.png]

Ejercicio 1: Análisis y Regresión Lineal - Precio del Dólar




8.2 Evidencia 2: Factores Determinantes en el Nivel de Glucosa

Archivo generado: `static/plots/glucosa_plots.png`
Descripción: Dispersiones clínicas de `Edad`, `IMC` y `Actividad_Fisica` vs `Nivel_Glucosa`, evidenciando el efecto protector del ejercicio y el riesgo asociado a la edad y peso.

[PEGAR AQUÍ IMAGEN: glucosa_plots.png]

Ejercicio 2: Factores Determinantes en el Nivel de Glucosa




8.3 Evidencia 3: Matriz de Correlación y Regresión del Consumo Energético

Archivo generado: static/plots/energia_plots.png
Descripción: Mapa de calor (Heatmap) de correlación de Pearson y gráficos de dispersión ajustados para **Temperatura**, **Hora** y **Dia_Semana** vs **Consumo_Energia**.

[PEGAR AQUÍ IMAGEN: energia_plots.png]

Ejercicio 3: Matriz de Correlación y Regresión de Consumo Energético



8.4 Evidencias 4, 5 y 6: Capturas de la Interfaz Web en Funcionamiento

Descripción: Pantallazos de la aplicación Streamlit en ejecución local o en la nube al calcular predicciones interactivas en tiempo real.

Captura 1: Módulo de Predicción del Precio del Dólar

[PEGAR AQUÍ CAPTURA DE PANTALLA: app.py - Módulo Dólar]

Captura 2: Módulo de Predicción de Niveles de Glucosa

[PEGAR AQUÍ CAPTURA DE PANTALLA: app.py - Módulo Glucosa]



Captura 3: Módulo de Predicción de Consumo de Energía



9. Conclusiones

1. **Robustez del Estándar CRISP-DM:** El seguimiento riguroso de las fases del estándar garantizó una transición lógica y trazable desde la formulación de preguntas analíticas hasta el despliegue de una solución de software utilizable por usuarios finales.
2. **Capacidad Explicativa del Modelo OLS:** La regresión lineal múltiple demostró un rendimiento predictivo sobresaliente en problemas donde las relaciones físicas o de tendencia son dominantes:
 - En el precio del dólar ($R^2 = 99.52\%$) por el patrón temporal determinístico.
 - En el consumo energético ($R^2 = 90.05\%$) por el efecto termodinámico directo de la temperatura sobre los sistemas de climatización.
3. **Valor Clínico de los Coeficientes:** En el análisis de salud ($R^2 = 68.55\%$), el modelo cuantificó matemáticamente que una hora adicional de ejercicio semanal compensa el impacto glucémico equivalente a casi dos años de envejecimiento ($\beta_{\text{Act}} = -2.01$ vs $\beta_{\text{Edad}} = +1.23$).
4. **Desacoplamiento Eficiente:** La persistencia binaria con **joblib** combinada con el frontend reactivo de **Streamlit** demostró ser una solución de alta eficiencia computacional, eliminando redundancias de re-entrenamiento en cada solicitud.

10. Referencias y Recursos Técnicos

- Chapman, P., Clinton, J., Kerber, R., et al. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*.
- Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. JMLR 12, pp. 2825-2830.
- Streamlit Documentation (2026). *Deploy Streamlit apps on Community Cloud*. <https://docs.streamlit.io>
- McKinney, W. (2010). *Data Structures for Statistical Computing in Python*, Proceedings of the 9th Python in Science Conference.